

# Prévoir la volatilité pour le market timing du facteur Momentum

Antonin Devalland

Janvier 2025

## Contents

<b>1</b>	<b>Pourquoi la volatilité du facteur Momentum ?</b>	<b>2</b>
<b>2</b>	<b>Méthodologie</b>	<b>3</b>
2.1	Données . . . . .	3
2.2	Définition des cibles . . . . .	4
2.3	Benchmark . . . . .	5
2.4	Modèles autorégressifs . . . . .	5
2.4.1	Modèles AR(1) . . . . .	5
2.4.2	Modèles HAR . . . . .	6
2.4.3	HAR-RS et HAR-SJ . . . . .	6
2.4.4	HAR-RS-X . . . . .	7
2.4.5	Modèles GARCH, EGARCH et GJR . . . . .	7
2.4.6	Stationnarité . . . . .	7
2.5	Modèles de Machine Learning . . . . .	8
2.5.1	Motivation . . . . .	8
2.5.2	Méthodologie . . . . .	9
2.5.3	Modèles . . . . .	9
2.6	Construction de portefeuilles . . . . .	9
<b>3</b>	<b>Résultats des prévisions</b>	<b>10</b>
3.1	Choix de l'horizon et de la fenêtre de calcul . . . . .	10
3.2	Comparaison des prévisions . . . . .	11
3.3	Analyse de features et des hyperparamètres . . . . .	12
3.4	Conclusion . . . . .	13
<b>4</b>	<b>Stratégies de portefeuille</b>	<b>14</b>
4.1	Stratégies de portefeuille avec modèles autorégressifs . . . . .	14
4.2	Stratégies de portefeuille avec Machine Learning . . . . .	15

# Introduction

La prévision de la volatilité occupe une place centrale en finance, tant pour la gestion du risque que pour la prise de décision en allocation d'actifs. Le premier objectif de ce projet est d'évaluer la capacité prédictive de modèles classiques de prévision de la volatilité appliqués au facteur Momentum, et de comparer leurs performances à celles de modèles de machine learning, susceptibles de mieux capturer des relations non linéaires et des dynamiques complexes.

Au-delà de la seule performance statistique des prévisions, ce travail vise également à analyser leur utilité économique. Plus précisément, nous étudions dans quelle mesure les prévisions de volatilité peuvent être intégrées dans des stratégies de gestion de portefeuille, notamment via des ajustements dynamiques de l'exposition au facteur Momentum, afin d'améliorer le contrôle du risque et la performance d'un portefeuille factoriel.

Le facteur Momentum constitue un cas d'étude particulièrement pertinent. Bien qu'il s'agisse de l'un des facteurs les plus performants historiquement, il est également caractérisé par une forte exposition à des épisodes de pertes extrêmes, communément appelés Momentum crashes. Ces épisodes se traduisent par une distribution des rendements fortement asymétrique, avec une skewness négative marquée et une kurtosis élevée. Dans ce contexte, le développement de stratégies efficaces de gestion du risque est crucial afin de limiter l'impact de ces crashes. L'utilisation de prévisions de volatilité permet notamment d'adapter l'exposition au facteur en amont des périodes de stress, contribuant ainsi à réduire l'asymétrie et l'épaisseur des queues de la distribution des rendements, et à améliorer le profil rendement-risque du facteur Momentum.

## 1 Pourquoi la volatilité du facteur Momentum ?

Prédire les rendements financiers est notoirement difficile. Les rendements sont fortement bruités, faiblement autocorrélés, et leur composante prévisible est généralement très faible. En revanche, la volatilité présente des propriétés statistiques beaucoup plus favorables à la prédiction. Premièrement, la volatilité est persistante : elle présente une forte autocorrélation et des phénomènes de clustering bien documentés. Deuxièmement, elle réagit de manière asymétrique aux chocs négatifs, ce qui la rend sensible à l'état du marché. Enfin, de nombreux modèles empiriques (GARCH, HAR, modèles à facteurs latents) montrent que la volatilité est bien décrite par des dynamiques lentes et prévisibles. Dans ce contexte, prédire la volatilité plutôt que les rendements permet de se concentrer sur une variable plus stable, plus structurée et économiquement plus exploitable. La figure 1 présente la présence de clustering ainsi que la forte autocorrélation de la variance comparée à celle des rendements.

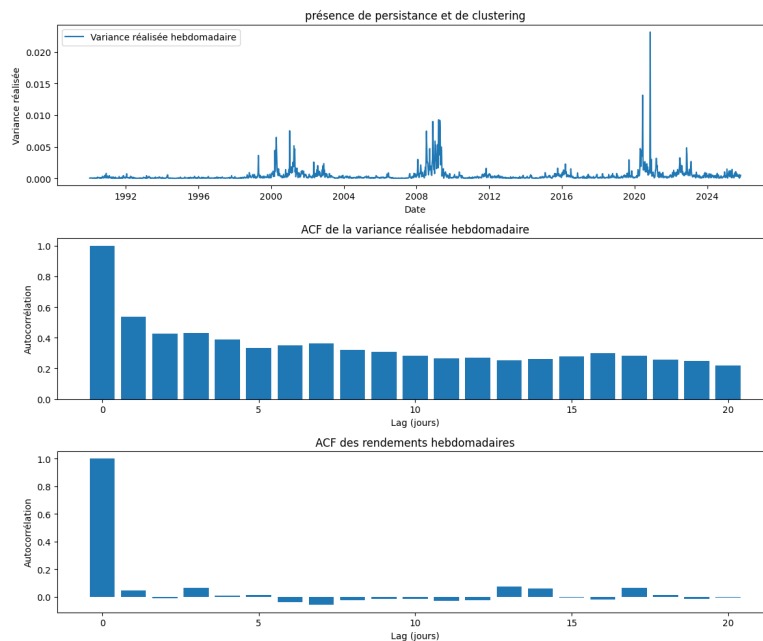


Figure 1: Variance réalisée hebdomadaire du facteur Momentum et ACF de la variance et des rendements

Le facteur Momentum est l'un des facteurs empiriques les plus robustes documentés en finance. Il repose sur une régularité simple : les actifs ayant récemment bien performé ont tendance à continuer de surperformer à court

et moyen terme, tandis que ceux ayant sous-performé continuent souvent de sous-performer. Formellement, une stratégie momentum consiste à acheter les actifs ayant les rendements passés les plus élevés et à vendre ceux ayant les rendements passés les plus faibles, typiquement sur des horizons de 3 à 12 mois.

Un point central de la littérature est que le lien entre volatilité et rendement est particulièrement marqué pour le facteur Momentum. Contrairement à l'intuition classique d'un arbitrage rendement-risque positif, de nombreux travaux montrent que les périodes de forte volatilité du Momentum sont associées à des rendements futurs faibles, voire négatifs. Ce phénomène s'explique notamment par la nature du Momentum, qui génère des pertes importantes lors de retournements de marché brusques. Les crashes du Momentum sont souvent concentrés après des périodes de forte volatilité ou de transitions macroéconomiques. Empiriquement, il est observé que la volatilité du Momentum augmente fortement avant et pendant ces épisodes de pertes extrêmes, ce qui suggère que la volatilité contient une information prédictive sur le risque asymétrique du facteur. Nous pouvons observer ce phénomène sur nos données sur la Figure 2.

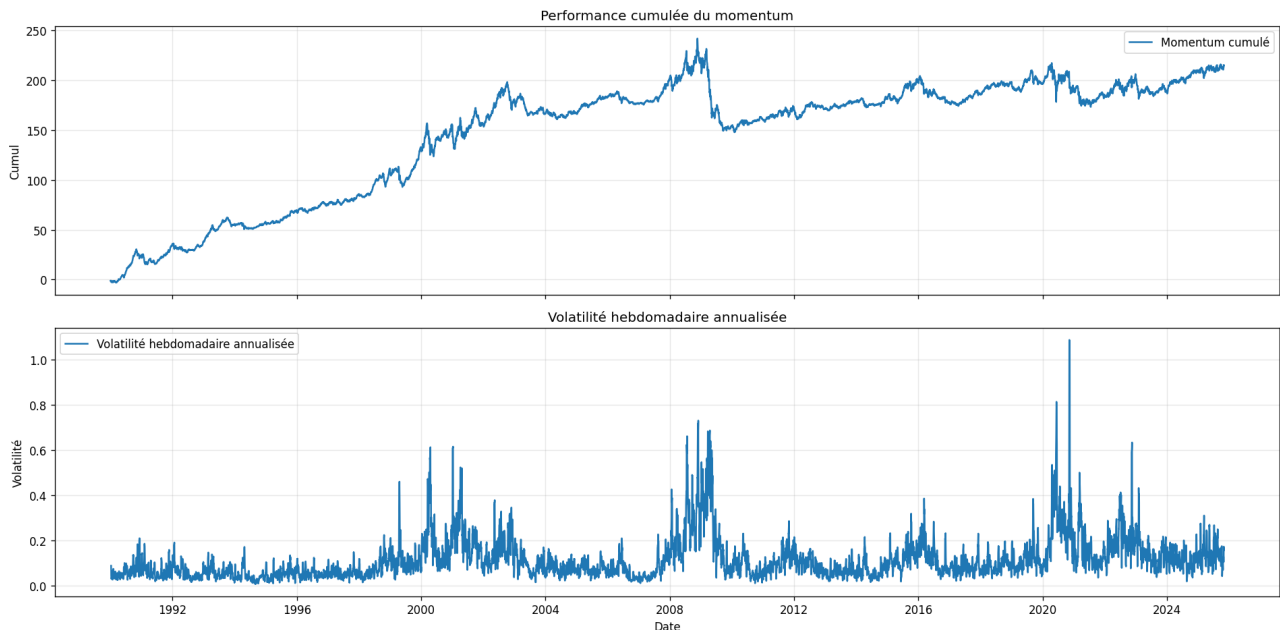


Figure 2: Volatilité et performance du facteur Momentum

## 2 Méthodologie

### 2.1 Données

Les variables utilisées combinent des indicateurs de marché, des facteurs de risque actions et des variables macro-financières. Elles incluent notamment des indices actions, des actifs obligataires, des variables liées au dollar et aux taux de change, ainsi que des indicateurs macro-financiers tels que les taux d'intérêt, les spreads de crédit, des indicateurs monétaires et l'indice de volatilité VIX. Nous intégrons également les facteurs de risque issus de la base de données de Kenneth French, à savoir les cinq facteurs de Fama–French ainsi que le facteur Momentum, qui constituent des variables centrales pour l'analyse des dynamiques de marché.

Les données sont observées à une fréquence journalière sur la période 1990–2025, ce qui permet de couvrir plusieurs cycles économiques, différents régimes de marché et des épisodes de stress financier marqués. Cette profondeur temporelle enrichit l'information disponible et permet d'analyser la robustesse des relations sur le long terme, au-delà des seuls rendements passés. Seules des variables cotées et observables en temps réel sont retenues, de manière à exclure toute fuite d'information liée à des délais ou des révisions de publication.

Un travail approfondi de *feature engineering* est ensuite réalisé afin de rendre ces variables exploitables dans un cadre de prévision. Les prix sont transformés en rendements logarithmiques afin d'assurer la stationnarité des séries, tandis que les variables macro-financières sont utilisées à la fois en niveau et en variation. Des mesures de volatilité réalisées sur différents horizons afin de capturer la persistance de la volatilité, et des retards temporels sont systématiquement introduits pour permettre aux modèles d'exploiter les dynamiques passées. Ce processus conduit à un ensemble riche de variables explicatives, tout en laissant aux modèles le soin

d'identifier les informations réellement pertinentes pour la prévision de la variance réalisée hebdomadaire.

## 2.2 Définition des cibles

Pour un horizon de  $h$  jours de trading, la variance réalisée future est définie par :

$$RV_t^{(h,f)} = \sum_{i=1}^h r_{t+i}^2,$$

qui correspond à la variance effectivement réalisée sur la période future  $[t + 1, t + h]$ . Trois horizons sont considérés : journalier ( $h = 1$ ), hebdomadaire ( $h = 5$ ) et mensuel ( $h = 21$ ).

La variance réalisée présente plusieurs propriétés statistiques qui rendent sa modélisation directe peu adaptée dans un cadre de prévision. Elle est strictement positive ; or de nombreux modèles standards, tels que les modèles AR ou HAR, ne respectent pas cette contrainte. Elle est fortement asymétrique : on observe un grand nombre de valeurs proches de zéro, peu de valeurs intermédiaires et de nombreuses valeurs extrêmes correspondant aux périodes de crise. La présence de ces valeurs extrêmes est problématique pour l'estimation, car quelques épisodes dominent l'apprentissage ; le modèle tend alors à surtout apprendre les crises et à mal prédire en régime normal. Elle est également caractérisée par une hétéroscédasticité marquée.

Afin de remédier à ces problèmes, nous considérons la transformation logarithmique de la variance réalisée. La log-variance présente une distribution nettement plus symétrique (la fonction logarithme étant concave, elle atténue l'impact des valeurs extrêmes) et une variance plus stable dans le temps, ce qui facilite son traitement statistique. Empiriquement, elle est souvent proche d'un processus stationnaire ou localement stationnaire, contrairement à la variance brute, dont le niveau moyen varie fortement entre régimes de marché calmes et turbulents. Cette transformation permet ainsi de réduire l'influence disproportionnée des périodes de crise et d'améliorer la stabilité des estimations et des performances hors échantillon.

De plus, les variations de la variance sont empiriquement de nature multiplicative en niveau : un même choc a un impact proportionnellement plus important lorsque la volatilité est élevée. En passant à l'échelle logarithmique, ces chocs deviennent additifs, ce qui rend les modèles linéaires autorégressifs, tels que les modèles AR ou HAR, plus appropriés et plus cohérents avec la dynamique observée de la volatilité.

Enfin, le choix de la variance plutôt que de la volatilité s'explique par le fait que la volatilité présente les mêmes difficultés statistiques que la variance et que, contrairement à cette dernière, elle ne s'additionne pas dans le temps. Par exemple, lors d'une annualisation, la volatilité doit être multipliée par  $\sqrt{h}$ , ce qui complique l'interprétation et l'agrégation intertemporelle.

La figure 3 présente à gauche la distribution des variances réalisées et à droite leur logarithme. Nous pouvons observer que le passage en logarithme offre une distribution beaucoup plus propice à l'estimation et à la prévision.

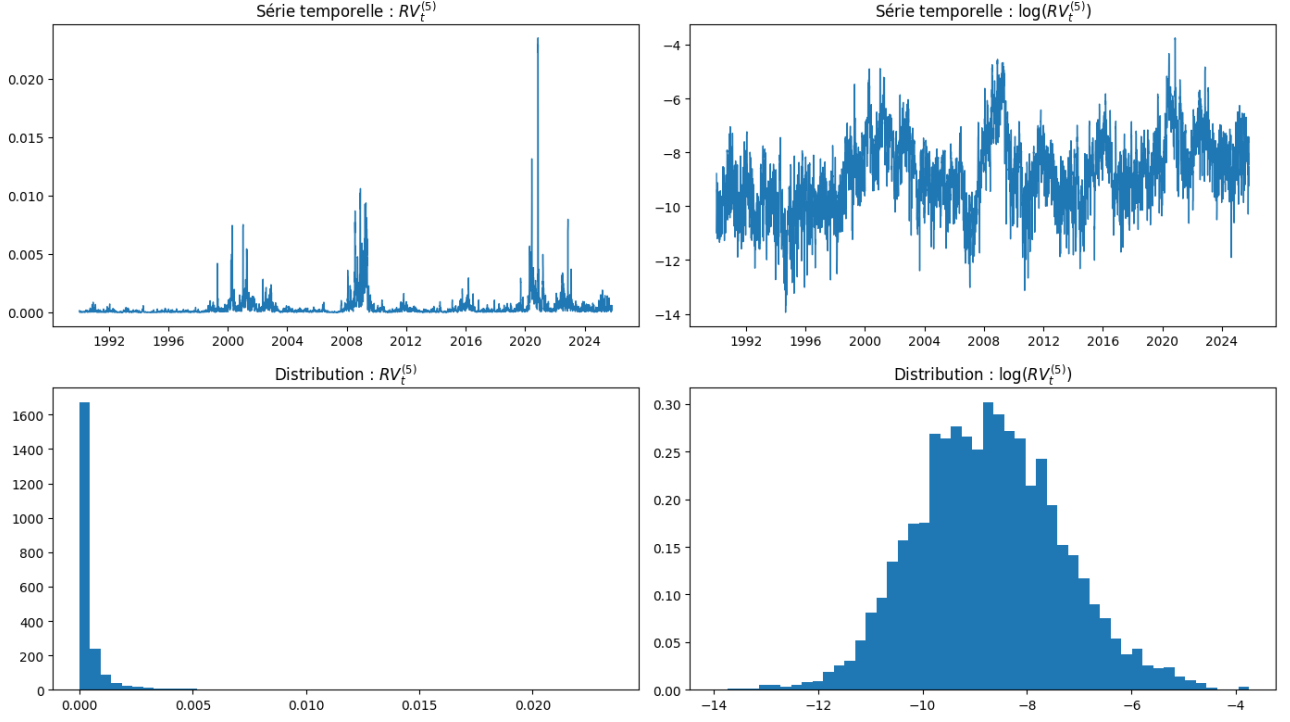


Figure 3: Distribution de la variance réalisée et de son logarithme.

La variance réalisée future étant strictement positive et fortement asymétrique, l'analyse est conduite sur sa transformation logarithmique,

$$y_t = \log\left(RV_t^{(h,f)}\right),$$

afin de stabiliser la variance et de réduire l'influence des observations extrêmes. Les cibles ainsi définies constituent des mesures du risque futur effectivement réalisé sur un horizon donné et servent de base à l'analyse empirique présentée dans la suite.

## 2.3 Benchmark

Comme benchmark, nous retenons une spécification de type marche aléatoire pour la log-variance, dans laquelle la log-variance prédite à la date  $t + 1$  est égale à la log-variance observée à la date  $t$ . Ce benchmark exploite la forte persistance, proche d'une racine unitaire, largement documentée dans les séries de volatilité financière. En conséquence, l'information marginale contenue dans des variables explicatives supplémentaires est souvent limitée à court horizon, ce qui rend ce benchmark particulièrement difficile à surpasser hors échantillon. Il constitue ainsi une référence exigeante pour évaluer les gains prédictifs réels apportés par des modèles plus complexes, qu'ils soient économétriques ou issus de l'apprentissage automatique.

## 2.4 Modèles autorégressifs

### 2.4.1 Modèles AR(1)

Comme points de départ, nous considérons des modèles linéaires standards pour la prévision de la volatilité, qui servent de références dans la littérature. Le modèle autorégressif d'ordre un (AR(1)) suppose que la volatilité future dépend uniquement de sa dernière réalisation observée. Appliqué à la variance réalisée future à horizon  $h$ , le modèle s'écrit :

$$y_t = \alpha + \rho y_{t-1} + \varepsilon_t,$$

où  $y_t = \log(RV_t^{(h,f)})$  désigne la transformation logarithmique de la variance réalisée future. Ce modèle capture la forte persistance empirique de la volatilité et constitue un benchmark naturel pour évaluer la performance de modèles plus complexes.

Les modèles AR(1) utilisés pour prédire la log-variance hebdomadaire (resp. mensuelle) reposent sur une série de log-variance hebdomadaire (resp. mensuelle) calculée toutes les semaines (resp. tous les mois) afin d'éviter les problèmes d'overlapping.

### 2.4.2 Modèles HAR

Nous considérons également une spécification de type *Heterogeneous Autoregressive* (HAR), aussi appelée *Heterogeneous AutoRegressive – Realized Volatility* (HAR-RV), largement utilisée pour modéliser la volatilité réalisée. L'idée du modèle HAR est que la volatilité présente une dynamique multi-horizon : les composantes de court, moyen et long terme (par exemple à fréquence journalière, hebdomadaire et mensuelle) contribuent conjointement à expliquer la volatilité future. Dans notre cadre, le modèle HAR s'écrit :

$$y_t = \alpha + \beta_d y_{t-1} + \beta_w y_{t-1}^{(5)} + \beta_m y_{t-1}^{(21)} + \varepsilon_t,$$

où  $y_{t-1}^{(5)}$  et  $y_{t-1}^{(21)}$  désignent respectivement les composantes hebdomadaire et mensuelle de la volatilité, construites à partir de  $y_t$  et observables à la date de prévision. Cette spécification fournit une approximation simple d'une dynamique à mémoire longue, tout en restant linéaire et facilement interprétable.

Pour la prédiction de la log-variance hebdomadaire et mensuelle avec les modèles HAR, la variable endogène est une série de log-variance hebdomadaire (resp. mensuelle), calculée comme le logarithme de la somme des variances journalières (2). Comme pour les modèles AR, ces séries sont construites à fréquence hebdomadaire ou mensuelle afin d'éviter l'overlapping.

### 2.4.3 HAR-RS et HAR-SJ

Nous étendons le modèle HAR afin de tenir compte des asymétries de la volatilité et de la nature directionnelle des chocs. En effet, de nombreux travaux montrent que les chocs négatifs sur les rendements contiennent plus d'information sur la volatilité future que les chocs positifs de même ampleur, en particulier en période de stress. Le modèle HAR with Realized Semivariance (HAR-RS) permet ainsi de distinguer l'impact des mouvements baissiers et haussiers, tandis que le modèle HAR with Signed Jumps (HAR-SJ) introduit une composante directionnelle des chocs, améliorant la capacité du modèle à capturer la dynamique non linéaire de la volatilité réalisée.

Dans les modèles HAR-SJ et HAR-RS classiques, ces composantes sont construites à partir de rendements intrajournaliers et agrégées au niveau journalier afin de prédire la volatilité réalisée du jour suivant. Dans notre cadre, la variable dépendante étant définie à une fréquence journalière, hebdomadaire ou mensuelle, nous adaptons cette approche en construisant des mesures d'asymétrie et de sauts signés à partir des données journalières, agrégées sur l'horizon temporel considéré.

À partir des rendements journaliers  $r_t$ , on définit ainsi la semi-variance négative agrégée

$$SV_t^- = \sum_{j=0}^{h-1} r_{t-j}^2 \mathbf{1}_{\{r_{t-j} < 0\}},$$

et le saut signé agrégé

$$Jump_t = \sum_{j=0}^{h-1} r_{t-j}^2 (\mathbf{1}_{\{r_{t-j} \geq 0\}} - \mathbf{1}_{\{r_{t-j} < 0\}}),$$

où  $h$  correspond à l'horizon de prévision considéré. Le modèle HAR-RS classique inclut la semi-variance négative et la semi-variance positive, tandis que le modèle HAR-SJ inclut le saut signé. Dans notre application, nous ne considérons que la semi-variance négative et le saut signé. Le modèle utilisé, que nous appellerons HAR-RS, s'écrit alors :

$$y_t = \alpha + \beta_d y_{t-1} + \beta_w y_{t-1}^{(5)} + \beta_m y_{t-1}^{(21)} + \gamma SV_{t-1}^- + \delta Jump_{t-1} + \varepsilon_t.$$

Si l'on considère par exemple la prévision de la log-variance hebdomadaire, le modèle HAR-RS est estimé avec une série de log-variance hebdomadaire (2), calculée à partir de données journalières, comme variable dépendante. Les semi-variances et le saut sont également calculés comme des agrégations hebdomadaires de données journalières.

#### 2.4.4 HAR-RS-X

Le modèle HAR-RS-X est une extension du modèle HAR-RS à laquelle est ajoutée une ou plusieurs variables exogènes. Afin de rester parcimonieux, nous ne considérons qu'une seule variable exogène par modèle. Le modèle incluant la variable VIX est retenu, car il présente les meilleures performances hors échantillon (OOS) parmi les différents modèles testés.

#### 2.4.5 Modèles GARCH, EGARCH et GJR

Contrairement aux autres modèles, les modèles de type GARCH sont estimés à partir de rendements journaliers et produisent des prévisions de variance conditionnelle à chaque horizon futur. À partir de ces prévisions journalières, le modèle génère successivement les  $h$  variances prévues aux horizons  $1, \dots, h$ , que nous agrégeons ensuite par sommation. La prévision finale de la log-variance à l'horizon  $h$  est obtenue en appliquant une transformation logarithmique à cette variance agrégée, ce qui permet de rendre les résultats comparables à ceux des autres approches.

Le modèle GARCH(1,1) capture la persistance de la variance conditionnelle en reliant celle-ci aux chocs passés et à sa propre dynamique. Le modèle s'écrit :

$$r_t = \mu + \varepsilon_t, \quad \varepsilon_t = \sigma_t z_t,$$

où  $z_t$  est une innovation standardisée de moyenne nulle et de variance unitaire. La variance conditionnelle suit alors la dynamique :

$$\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2,$$

avec  $\omega > 0$ ,  $\alpha, \beta \geq 0$  et  $\alpha + \beta < 1$  afin d'assurer la stationnarité.

Le modèle EGARCH (Exponential GARCH) modélise la dynamique de la variance sur une échelle logarithmique, ce qui garantit sa positivité sans imposer de contraintes paramétriques explicites :

$$\log \sigma_t^2 = \omega + \beta \log \sigma_{t-1}^2 + \alpha \left( \frac{|\varepsilon_{t-1}|}{\sigma_{t-1}} - \mathbb{E}|z| \right) + \gamma \frac{\varepsilon_{t-1}}{\sigma_{t-1}}.$$

Le terme asymétrique  $\gamma$  permet de capturer l'effet de levier, selon lequel les chocs négatifs ont un impact plus important sur la volatilité future. Cette flexibilité améliore souvent les performances prédictives, notamment lors de périodes de stress de marché.

Le modèle GJR-GARCH introduit une asymétrie directement dans la dynamique de la variance conditionnelle via un indicateur de chocs négatifs :

$$\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \gamma \mathbb{I}_{\{\varepsilon_{t-1} < 0\}} \varepsilon_{t-1} + \beta \sigma_{t-1}^2.$$

Ce modèle permet de distinguer l'impact des rendements négatifs et positifs sur la variance future.

Dans les modèles de type GARCH, l'hypothèse de distribution porte sur les innovations standardisées. Plus précisément, si  $\varepsilon_t$  désigne le choc de rendement et  $\sigma_t^2$  la variance conditionnelle, on écrit :

$$\varepsilon_t = \sigma_t z_t, \quad z_t \sim \mathcal{D}(0, 1),$$

où  $\mathcal{D}$  désigne une loi centrée et de variance unitaire.

Plusieurs choix sont possibles pour la distribution de  $z_t$ , notamment la loi normale, la loi de Student, ou des distributions plus flexibles telles que la loi de Student asymétrique ou la loi GED (Generalized Error Distribution). Dans ce travail, nous retenons principalement les spécifications gaussienne et Student, cette dernière permettant de mieux capturer les queues épaisses fréquemment observées dans les rendements financiers.

#### 2.4.6 Stationnarité

Dans la littérature sur la prévision de la volatilité réalisée, l'utilisation de modèles autorégressifs appliqués directement à la RV ou à la log-RV s'accompagne souvent d'estimations en fenêtres glissantes de durée relativement courte (5 à 10 ans). Il est important de souligner que cette pratique ne vise pas à restaurer la stationnarité de la variance observée. Au contraire, lorsque des épisodes de crise représentent une part significative de la fenêtre considérée, la série de log-RV reste clairement non stationnaire : son niveau moyen varie fortement et

la dynamique estimée mélange des régimes de volatilité très différents. Le recours à une fenêtre glissante peut ainsi amplifier l'instabilité apparente en faisant varier brusquement les paramètres estimés lorsque les périodes de crise entrent ou sortent de la fenêtre.

Nos résultats confirment cette idée, puisque nos séries sont stationnaires sur l'ensemble de la période étudiée. En revanche, sur des fenêtres glissantes de 5 ou 10 ans, on peut parfois observer une forte non-stationnarité lorsque des périodes de crise sont présentes dans la fenêtre considérée. Dans ce cas, la non-stationnarité provient naturellement d'une proportion plus élevée de la fenêtre glissante correspondant à une période de crise, comparativement à cette proportion sur la période totale.

Néanmoins, cette approche est largement adoptée dans un cadre de prévision, où l'objectif n'est pas l'identification d'une dynamique structurelle stationnaire de long terme, mais la production de prévisions à court et moyen horizons à partir de l'information la plus récente. Dans ce contexte, les coefficients estimés dans des modèles de type AR ou HAR ne peuvent pas être interprétés comme des paramètres structurels invariants, ni faire l'objet d'une inférence statistique standard. Ils doivent plutôt être compris comme des paramètres réduits, locaux et dépendants du régime, dont la valeur réside essentiellement dans leur capacité à résumer l'information contenue dans les observations récentes et à produire des prévisions opérationnelles, au prix d'une perte d'interprétation économique et de validité des tests usuels.

Même lorsque l'inférence classique sur les coefficients n'est pas valide, en raison de la forte persistance ou d'une non-stationnarité locale de la volatilité, ces modèles peuvent néanmoins servir de benchmarks de prévision utiles. La variance des rendements étant fortement autocorrélée et caractérisée par un clustering temporel marqué, l'information récente joue un rôle central dans la prévision. En contrepartie, cette forte persistance limite généralement les gains par rapport à des règles simples, comme l'utilisation de la dernière observation disponible. L'intérêt de ces modèles réside ainsi principalement dans leur utilité opérationnelle pour la prévision hors échantillon, plutôt que dans l'interprétation économique des coefficients.

Notre objectif étant exclusivement la prévision à court terme, et non l'estimation ou l'interprétation des paramètres, nous nous concentrons sur les performances hors échantillon, sans imposer les hypothèses classiques d'inférence telles que l'exogénéité, l'absence de multicolinéarité ou la sphéricité des erreurs.

## 2.5 Modèles de Machine Learning

### 2.5.1 Motivation

Dans ce projet, les modèles économétriques classiques, tels que les modèles AR, HAR ou GARCH, constituent des références naturelles, car ils capturent efficacement la forte persistance de la volatilité et son caractère autorégressif. Leur structure paramétrique simple permet de résumer l'essentiel de la "mémoire" de la volatilité à partir de ses réalisations passées. En revanche, ces modèles reposent sur des relations essentiellement linéaires et sur un nombre limité de variables explicatives, ce qui restreint leur capacité à intégrer l'information contenue dans un environnement macroéconomique riche et potentiellement instable.

Dans le contexte de la volatilité du facteur Momentum, l'impact des variables macrofinancières est susceptible d'être non linéaire, conditionnel à l'état du marché et marqué par des effets de seuil ou des changements de régime. Par exemple, certaines variables peuvent devenir informatives uniquement en période de stress élevé, tandis qu'elles sont peu pertinentes en régime normal. Les modèles économétriques linéaires peinent à capturer ce type de comportement, sauf au prix de spécifications complexes et rapidement instables hors échantillon.

Les modèles de machine learning offrent une alternative adaptée à ces contraintes. Ils permettent de traiter simultanément un grand nombre de variables explicatives sans imposer de relation fonctionnelle prédéfinie, ce qui les rend particulièrement aptes à exploiter l'information contenue dans des ensembles de variables macroéconomiques de grande dimension. Ils sont également capables d'apprendre des interactions non linéaires et des effets de seuil entre les variables, sans qu'il soit nécessaire de les spécifier explicitement *ex ante*.

Dans ce cadre, l'objectif n'est pas de remplacer les modèles économétriques, mais de les compléter. Les modèles classiques fournissent des benchmarks interprétables et robustes, fondés sur la persistance de la volatilité, tandis que les approches de machine learning permettent d'explorer si l'information macroéconomique supplémentaire contient un pouvoir prédictif marginal, notamment lors des phases de transition ou de stress de marché. L'intérêt des modèles de machine learning réside ainsi principalement dans leur capacité à améliorer la prévision hors échantillon en exploitant des structures complexes que les modèles linéaires traditionnels ne peuvent pas capter efficacement.

### 2.5.2 Méthodologie

Afin d'éviter tout *look-ahead bias*, nous utilisons une procédure de validation *walk forward* implémentée via la fonction `sklearn.walk_forward`. Cette approche respecte strictement la chronologie de l'information disponible sur les marchés financiers et garantit que les modèles sont entraînés, sélectionnés et évalués dans des conditions réalistes. À chaque date  $t$ , la procédure suit les étapes suivantes :

1. L'ensemble des données disponibles jusqu'à la date  $t$  est scindé en deux sous-échantillons chronologiquement ordonnés. Le premier correspond à une fenêtre historique ancienne utilisée pour l'apprentissage du modèle, tandis que le second correspond à une fenêtre plus récente utilisée pour la validation. À titre d'illustration, la fenêtre d'apprentissage peut couvrir la période allant de  $t - 20$  à  $t - 5$ , et la fenêtre de validation la période allant de  $t - 5$  à  $t$ .
2. Pour chaque combinaison d'hyperparamètres considérée, le modèle est estimé uniquement sur la fenêtre d'apprentissage, puis évalué sur la fenêtre de validation à l'aide d'un critère de performance (RMSE). La combinaison d'hyperparamètres minimisant l'erreur de validation est retenue.
3. Une fois la configuration optimale identifiée, le modèle est ré-estimé sur l'ensemble des données disponibles jusqu'à la date  $t$  (fenêtres d'apprentissage et de validation réunies), afin d'exploiter toute l'information observable à cette date.
4. Le modèle ainsi estimé est ensuite utilisé pour produire une prévision hors échantillon de la volatilité à l'horizon  $t + h$ .
5. Afin de limiter le coût computationnel, la recherche d'hyperparamètres et la ré-estimation complète du modèle ne sont effectuées aussi régulièrement que la prédiction. Il est par exemple possible d'estimer le modèle et de sélectionner les hyperparamètres tous les mois, tout en produisant une prévision quotidienne.

### 2.5.3 Modèles

Dans un contexte caractérisé par un grand nombre de variables explicatives macro-financières, leurs transformations et leurs retards, les méthodes de machine learning offrent un cadre particulièrement adapté pour la prévision de la volatilité. Ces approches permettent d'exploiter efficacement une information riche et potentiellement redondante, tout en dépassant les limites des modèles économétriques linéaires classiques.

L'Elastic Net constitue un point d'entrée naturel dans cette famille de modèles. Il est particulièrement pertinent en présence d'un espace de variables explicatives de grande dimension et de fortes corrélations entre celles-ci. En combinant les pénalités Lasso et Ridge, l'Elastic Net permet à la fois de sélectionner automatiquement les variables les plus informatives et de stabiliser l'estimation des coefficients lorsque les variables sont fortement corrélées. Cette régularisation réduit le risque de sur-apprentissage et améliore la robustesse des performances hors échantillon. Par ailleurs, l'Elastic Net occupe une position intermédiaire particulièrement intéressante entre les modèles économétriques classiques et les méthodes de machine learning plus complexes : il conserve une structure linéaire simple et efficace pour la prévision de la variance, tout en étant capable d'intégrer et de sélectionner un grand nombre de variables macro-financières supplémentaires. Il constitue ainsi un compromis naturel entre interprétabilité, parcimonie et capacité prédictive.

Les méthodes à base d'arbres, et en particulier LightGBM, permettent d'aller au-delà de ce cadre linéaire. Grâce à sa structure de boosting d'arbres de décision, LightGBM est capable de modéliser des relations non linéaires et des interactions complexes entre les variables explicatives, sans imposer de forme fonctionnelle a priori. Dans un environnement macro-financier riche, l'impact de certaines variables sur la volatilité peut dépendre de l'état du marché ou du niveau d'autres variables, ce que les modèles linéaires peinent à capturer. LightGBM identifie automatiquement des effets de seuil, des changements de régime et des interactions pertinentes, tout en restant performant en haute dimension. Ses mécanismes de régularisation et sa capacité à gérer efficacement de grands ensembles de données en font un outil particulièrement adapté à l'amélioration des performances de prévision hors échantillon de la variance réalisée hebdomadaire.

## 2.6 Construction de portefeuilles

Dans de nombreux cadres de gestion, l'allocation ne dépend pas d'une anticipation des rendements qui est difficile et instable mais du niveau de risque anticipé. Cette approche est particulièrement pertinente pour le facteur Momentum, dont les rendements sont caractérisés par une forte asymétrie et des épisodes de pertes soudaines, souvent précédés d'une hausse marquée de la volatilité.

Afin d'évaluer l'intérêt économique de ces prévisions, nous considérons des portefeuilles simples à deux actifs, composés du facteur Momentum et d'un actif alternatif. Les Treasury Bills américains à 3 mois représentent un actif de repli naturel, permettant de réduire l'exposition au Momentum lorsque la variance anticipée est élevée. En complément, l'utilisation de facteurs actions tels que CMA, HML et RMW est économiquement pertinente, car ces facteurs présentent des profils de risque distincts voir complémentaires à Momentum et sont historiquement moins exposés aux épisodes de *momentum crashes*. Une allocation dynamique entre Momentum et ces facteurs permet ainsi d'évaluer si la prévision de variance contient une information exploitable pour améliorer la gestion du risque et la performance ajustée du risque d'un portefeuille factoriel.

Les stratégies de *volatility targeting* sont des approches d'allocation de portefeuille dans lesquelles l'exposition à un actif risqué est ajustée dynamiquement afin de maintenir un niveau de risque constant dans le temps. Contrairement aux stratégies à pondérations fixes, le poids de l'actif risqué dépend ici de la volatilité conditionnelle anticipée.

Le principe fondamental consiste à définir une volatilité cible, interprétée comme un budget de risque *ex ante*, puis à ajuster l'exposition au risque de manière à ce que la volatilité prévue du portefeuille soit proche de cette cible. Soit  $r_{t+1}$  le rendement d'un actif risqué et  $\hat{\sigma}_{t+1}$  sa volatilité conditionnelle prévue à partir de l'information disponible à la date  $t$ . La règle de ciblage de la volatilité s'écrit alors :

$$w_t = \frac{\sigma^*}{\hat{\sigma}_{t+1}},$$

où  $\sigma^*$  désigne la volatilité cible. Lorsque la volatilité anticipée augmente, l'exposition à l'actif risqué est réduite ; inversement, lorsque la volatilité anticipée diminue, l'exposition est augmentée.

### 3 Résultats des prévisions

#### 3.1 Choix de l'horizon et de la fenêtre de calcul

Nous présentons dans un premier temps des résultats intermédiaires visant à déterminer l'horizon de prévision ainsi que la fenêtre d'estimation les plus appropriés.

Table 1: Comparaison des performances de prévision de variance mensuelle (RMSE)

Modèle	RW (10 ans)	RW (20 ans)	Expanding Window
Last Value	0,697	0,697	0,697
AR(1) mensuel	0,679	0,648	0,653
HAR	0,672	0,646	0,647
LHAR	0,670	0,631	0,631
LHAR-X (VIX)	0,659	0,616	0,620
GARCH(1,1)	0,656	0,641	0,639
GARCH (1,1) Student	0,653	0,639	0,638
EGARCH(1,1)	0,667	0,654	0,644
EGARCH(1,1) Student	0,654	0,641	0,635
GJR(1, 1)	0,641	0,633	0,630

Table 2: Comparaison des performances de prévision de variance hebdomadaire (RMSE)

Modèle	RW (10 ans)	RW (15 ans)	Expanding Window
Last Value	1,048	1,048	1,048
AR(1) hebdomadaire	0,939	0,933	0,944
HAR	0,851	0,862	0,851
LHAR	0,861	0,864	0,853
LHAR-X (VIX)	0,849	0,852	0,845
GARCH(1,1)	0,875	0,889	0,871
GARCH(1,1) Student	0,873	0,888	0,886
EGARCH(1,1)	0,883	0,898	0,892
EGARCH(1,1) Student	0,878	0,893	0,872
GJR(1,1)	0,870	0,884	0,864

Table 3: Comparaison des performances de prévision de variance journalière (RMSE)

Modèle	RW (5 ans)	RW (10 ans)	Expanding Window
Last Value	3,414	3,414	3,414
AR(1) journalier	2,651	2,651	2,674
HAR	2,450	2,433	2,433
LHAR	2,451	2,433	2,433
LHAR-X (VIX)	2,447	2,429	2,431
GARCH(1,1)	2,810	2,773	2,767
GARCH(1,1) Student	2,809	2,772	2,767
EGARCH(1,1)	2,816	2,781	2,775
EGARCH(1,1) Student	2,834	2,779	2,774
GJR(1,1)	2,808	2,772	2,766

Nous retenons un horizon de prédiction hebdomadaire pour plusieurs raisons :

- Premièrement, à un horizon journalier, la variance est trop bruitée et insuffisamment stable, ce qui rend les prévisions plus difficiles et moins fiables.
- Deuxièmement, pour un portefeuille, un rebalancement journalier est trop coûteux en pratique.
- Enfin, une prévision mensuelle n'est pas suffisamment réactive. Un crash très brutal peut se produire entre deux dates de prévision et ne serait alors pas détecté à temps.

Par ailleurs, pour les modèles économétriques, nous retenons une fenêtre glissante de 10 ans, qui présente les meilleures performances empiriques. Ce choix correspond à un compromis biais-variance que nous jugeons le plus pertinent : une fenêtre trop courte (par exemple 3 à 5 ans) conduit à des paramètres très instables, en raison d'une variance d'estimation élevée liée au faible nombre d'observations, tandis qu'une fenêtre trop longue (20 ans ou une fenêtre expansive) produit des paramètres plus stables mais potentiellement biaisés en cas de changement de régime.

### 3.2 Comparaison des prévisions

Table 4: Comparaison de la précision des prévision de variance hebdomadaire hors échantillon

Modèle	RMSE
Last Value	1,007
AR(1) hebdomadaire	0,932
LHAR	0,869
LHAR-X (VIX)	0,854
GARCH(1,1) Student	0,878
GJR(1,1)	0,886
Elastic Net	0,837
LightGBM	0,851

La Table 4 compare la précision des prévisions hors échantillon de la variance réalisée hebdomadaire à l'aide de la RMSE (plus la RMSE est faible, meilleure est la performance). Le benchmark *Last Value* (marche aléatoire sur la variance) obtient une RMSE de 1,007, ce qui constitue une référence exigeante compte tenu de la forte persistance de la volatilité.

Les résultats montrent tout d'abord que l'ensemble des modèles testés surpasse le benchmark, ce qui suggère l'existence d'un contenu prédictif exploitable au-delà de la simple persistance de la variance. Parmi les modèles économétriques, l'AR(1) hebdomadaire améliore modestement la prévision (RMSE = 0,932), tandis que les spécifications multi-horizon de type HAR offrent des gains nettement plus marqués (LHAR : 0,869). L'ajout d'une variable exogène de type indicateur de stress, ici le VIX, améliore encore la performance (LHAR-X : 0,854), ce qui confirme que l'information de marché contenue dans le VIX apporte un pouvoir prédictif marginal pour la variance du Momentum.

Les modèles de type GARCH se situent à un niveau de performance intermédiaire. La spécification GARCH(1,1) avec innovations Student (0,878) et le modèle asymétrique GJR(1,1) (0,886) battent le benchmark, mais restent

moins performants que les approches HAR enrichies. Cela est cohérent avec le fait que les modèles GARCH sont calibrés sur les rendements journaliers et capturent principalement la dynamique conditionnelle à très court terme, alors que la cible est une variance agrégée à horizon hebdomadaire.

Enfin, les modèles de machine learning affichent les meilleures performances hors échantillon. L'Elastic Net obtient la RMSE la plus faible (0,837), suivi de LightGBM (0,851). Ces résultats suggèrent qu'en présence d'un grand nombre de variables macro-financières, de transformations et de retards, la régularisation et la sélection automatique de variables (Elastic Net) permettent d'extraire efficacement l'information prédictive tout en limitant le sur-apprentissage. Le fait que LightGBM ne surpasse pas l'Elastic Net indique que, sur cette cible hebdomadaire, l'essentiel du pouvoir prédictif marginal semble provenir d'un enrichissement linéaire parcimonieux plutôt que d'effets non linéaires complexes, ou bien que ces non-linéarités sont plus difficiles à généraliser hors échantillon sur la période étudiée.

Globalement, la hiérarchie des performances met en évidence trois points : (i) les dynamiques multi-horizon de type HAR constituent des benchmarks robustes pour la variance hebdomadaire ; (ii) l'ajout d'un indicateur de stress tel que le VIX améliore significativement la précision ; (iii) l'exploitation d'un ensemble riche de variables via des méthodes de machine learning, en particulier l'Elastic Net, fournit les gains les plus importants en termes de RMSE hors échantillon.

### 3.3 Analyse de features et des hyperparamètres

Le modèle Elastic Net retient des hyperparamètres caractérisés par un ratio  $\ell_1$  compris entre 0,5 et 1, ce qui indique une régularisation majoritairement de type Lasso. Cela implique que de nombreux coefficients sont exactement nuls. Plusieurs éléments peuvent expliquer ce résultat. Tout d'abord, l'espace des variables explicatives est de grande dimension et contient de nombreuses variables peu ou pas pertinentes pour la prévision de la variance hebdomadaire. C'est notamment le cas de certaines *features* construites à partir des variables macro-financières (variances, retards, transformations, etc.). Ensuite, cette forte parcimonie suggère que certaines variables dominent largement l'estimation, en particulier les mesures de variance retardée et le VIX.

Le modèle sélectionne également une valeur de pénalisation globale  $\alpha$  relativement élevée, comprise entre 0,01 et 0,1. Cela indique que le modèle retenu est fortement régularisé et adopte une approche prudente afin de limiter un risque potentiel de sur-apprentissage. Ce choix est cohérent avec le contexte étudié, caractérisé par un grand nombre de variables explicatives et par des changements fréquents de régimes macroéconomiques, qui rendent nécessaire une régularisation forte pour éviter l'apprentissage de relations instables.

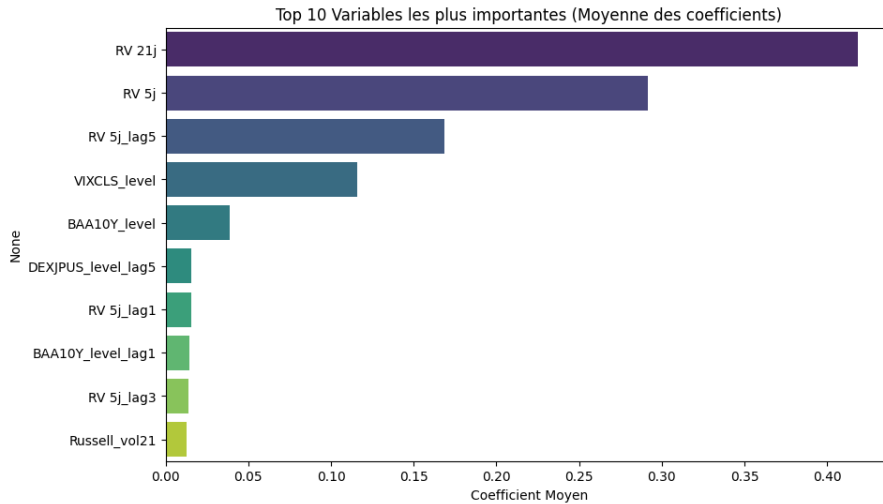


Figure 4: Features de l'Elastic Net

Les variables contribuant le plus à la prévision de la variance hebdomadaire sont principalement la log-variance mensuelle, la log-variance hebdomadaire et la log-variance hebdomadaire retardée. Viennent ensuite quelques variables macro-financières d'importance secondaire, telles que le VIX, les spreads de crédit et la force du dollar. On retrouve ainsi des mesures de log-variance à différents horizons temporels, ce qui indique qu'une large part de la structure du modèle est proche de celle d'un modèle HAR. La variance hebdomadaire dépend avant tout de ses propres retards calculés sur plusieurs fenêtres temporelles. La première variable macro-financière sélectionnée est le VIX, ce qui est cohérent avec les bonnes performances observées pour le modèle HAR-X incluant cet indicateur. Les spreads de crédit (BAA10Y) et le taux de change du dollar (DEXJPUS)

apparaissent également, mais avec des coefficients plus faibles, suggérant qu'ils contribuent à la prévision dans certaines configurations de marché sans constituer des déterminants centraux de la dynamique de la volatilité.

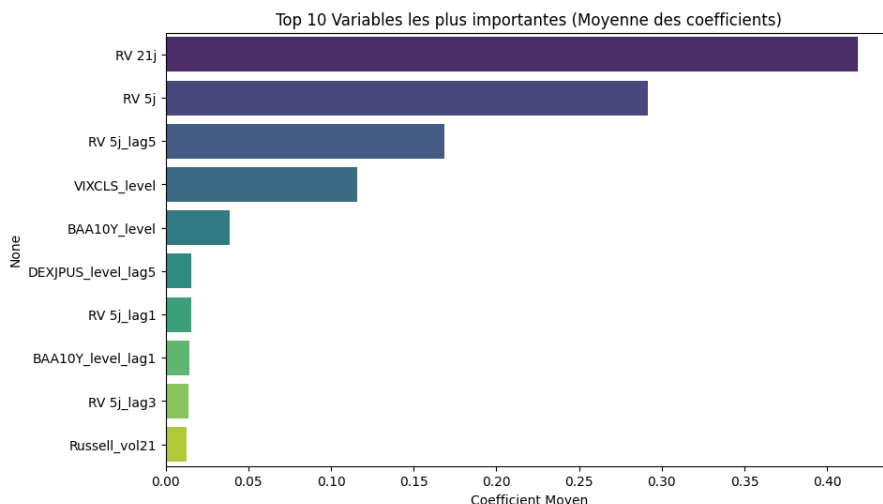


Figure 5: Features du LightGBM

La figure 5 montre que le modèle LightGBM accorde une importance encore plus marquée aux variances retardées. L'évolution des hyperparamètres sélectionnés met en évidence une complexité globale relativement limitée du modèle. La profondeur maximale des arbres retenue est presque toujours faible, ce qui indique que la relation entre les variables explicatives et la log-variance hebdomadaire peut être décrite à l'aide d'interactions simples et d'effets de seuil, sans nécessiter de structures non linéaires profondes. Cela suggère que l'essentiel du signal prédictif demeure relativement simple, en cohérence avec la forte persistance de la volatilité mise en évidence par les modèles linéaires.

En revanche, le *learning rate* varie davantage au cours du temps, traduisant une adaptation du compromis biais-variance selon les périodes et les régimes de marché. Dans certaines fenêtres, le modèle apprend de manière plus prudente, tandis que dans d'autres il ajuste plus rapidement ses paramètres. Ces résultats montrent que l'intérêt de LightGBM ne réside pas dans une complexité excessive, mais dans sa capacité à capter des non-linéarités locales et à s'adapter aux changements de régime, tout en conservant une structure prédictive stable hors échantillon.

### 3.4 Conclusion

Au vu des résultats, les modèles de machine learning n'apportent pas une rupture radicale par rapport aux modèles économétriques classiques mais offre des gains de prédictions réels. La dynamique de la volatilité est avant tout gouvernée par sa forte persistance, ce que confirment à la fois les modèles HAR et les résultats de sélection des variables par l'Elastic Net, où les mesures de volatilité passée dominent largement les autres variables explicatives.

L'Elastic Net met en évidence que cette information est concentrée dans un petit sous-ensemble de variables, principalement dans la variance lagée et ensuite des variables macro liées à l'aversion au risque et aux conditions financières : VIX, spread de crédit et force du dollar. Il permet de sélectionner des variables parmi un grand nombre de features lorsque nous savons pas exactement lesquelles ont de l'information prédictives. Les autres variables sont redondantes et ne sont pas utiles.

LightGBM, quant à lui, améliore marginalement la prévision en capturant des non-linéarités simples et des effets de seuil, sans recourir à une complexité excessive, comme en témoigne la faible profondeur des arbres sélectionnés. Cela nous indique que les relations entre nos features et la log-variance future sont linéaire ou alors peu complexes.

## 4 Stratégies de portefeuille

### 4.1 Stratégies de portefeuille avec modèles autorégressifs

Nous testons les stratégies de portefeuille à partir de 2001. Ce choix permet d'inclure la crise financière de 2008 dans la période hors échantillon, afin d'évaluer le comportement des stratégies lors d'un épisode de stress majeur. En contrepartie, cette période initiale ne fournit pas un nombre suffisant d'observations pour l'estimation et la validation fiables des modèles de machine learning, qui nécessitent des échantillons plus larges. Les résultats associés aux stratégies basées sur les modèles de machine learning sont donc présentés dans une section ultérieure.

<b>Volatily targeting</b>	$\mu_{ann}$	$\sigma_{ann}$	<b>SR</b>	<b>Skew</b>	<b>Kurt</b>	$\sigma_{cible}$
Buy and Hold Mom	2,9%	16,6%	0,17	-1,0	11,8	
Last value Mom/CMA hebdo	4,2%	8,0%	0,52	-0,5	3,9	5%
Last value Mom/CMA hebdo	6,5%	12,8%	0,51	-0,5	2,6	10%
LHAR-X VIX Mom/CMA hebdo	4,0%	7,7%	0,52	-0,5	4,0	5%
LHAR-X VIX Mom/CMA hebdo	6,8%	12,7%	0,54	-0,5	1,8	10%
GJR Mom/CMA hebdo	3,6%	7,2%	0,50	-0,5	4,8	5%
GJR Mom/CMA hebdo	5,8%	11,1%	0,53	-0,5	2,4	10%

Une première conclusion s'impose à ce stade. La stratégie de *volatility targeting* présente des performances très élevées : elle permet notamment de presque doubler le ratio de Sharpe et d'améliorer significativement le contrôle du couple rendement–risque, à Sharpe équivalent. Il est ainsi possible de choisir un niveau de risque cible sans détériorer la performance globale de la stratégie.

Une seconde conclusion concerne l'origine des gains de performance. Ceux-ci proviennent en grande partie du mécanisme de *volatility targeting* lui-même, indépendamment de la mesure de volatilité utilisée. Par exemple, l'utilisation de la dernière valeur observée de la variance (*last value*) génère des gains presque aussi élevés que ceux obtenus à partir des variances prédites par les différents modèles.

Dans la suite de l'analyse, nous nous concentrons uniquement sur la série de variance prédite par le modèle LHAR-X incluant le VIX, et évaluons les performances de la stratégie de *volatility targeting* pour différents actifs financiers.

<b>Volatily targeting</b>	$\mu_{ann}$	$\sigma_{ann}$	<b>SR</b>	<b>Skew</b>	<b>Kurt</b>	$\sigma_{cible}$
LHAR-X VIX Mom/CMA hebdo	4,0%	7,7%	0,52	-0,5	4,0	5%
LHAR-X VIX Mom/CMA hebdo	6,8%	12,7%	0,54	-0,5	1,8	10%
LHAR-X VIX Mom/RMW hebdo	5,2%	7,9%	0,66	-0,2	3,2	5%
LHAR-X VIX Mom/RMW hebdo	6,4%	11,2%	0,55	-0,4	1,9	10%
LHAR-X VIX Mom/HML hebdo	3,5%	9,4%	0,37	-0,2	5,9	5%
LHAR-X VIX Mom/HML hebdo	6,1%	11,3%	0,54	-0,5	2,1	10%
LHAR-X VIX Mom/T-bills hebdo	3,6%	4,2%	0,70	-0,5	2,3	5%
LHAR-X VIX Mom/T-bills hebdo	5,4%	10,3%	0,52	-0,5	2,5	10%

Les facteurs CMA et RMW offrent une combinaison particulièrement efficace pour remplacer l'exposition au facteur Momentum en période de crise et de forte volatilité, ce qui s'explique par leurs profils de risque très complémentaires. Ces facteurs présentent une meilleure résilience lors des phases de stress de marché et permettent ainsi de réduire significativement les pertes associées aux épisodes de *momentum crashes*.

En revanche, le facteur Value apparaît moins performant que les deux facteurs précédents dans ce cadre. Cela s'explique en partie par le caractère cyclique du facteur Value, qui, bien qu'il puisse se montrer résistant lors de certaines crises, demeure vulnérable à des chocs macroéconomiques spécifiques. Par exemple, lors de la crise liée au COVID-19 en 2020, le facteur Momentum a subi des pertes importantes, mais le facteur Value a également fortement souffert, tandis que les facteurs RMW et CMA ont relativement bien résisté. Par ailleurs, bien que les facteurs Momentum et Value soient historiquement considérés comme complémentaires en raison de leur corrélation négative élevée, les performances du facteur Value sont structurellement plus faibles depuis le début des années 2000, ce qui limite son intérêt dans les stratégies étudiées.

Enfin, la stratégie combinant le facteur Momentum avec les Treasury Bills s'avère également très performante. En effet, aucun facteur actions n'est totalement à l'abri en cas de crise majeure et de forte volatilité, y compris les facteurs dits défensifs tels que CMA, RMW ou HML. Dans ces conditions, la détention d'un actif sans risque constitue une solution efficace pour protéger le portefeuille et stabiliser le profil de risque lors des périodes de stress.

## 4.2 Stratégies de portefeuille avec Machine Learning

Stratégies	$\mu_{ann}$	$\sigma_{ann}$	SR	Skew	Kurt	$\sigma_{cible}$
Momentum buy & hold (bench)	4,3%	15,4%	0,28	-1,3	16,3	x
LHAR-X VIX Mom/CMA hebdo	5,0%	9,8%	0,51	-0,5	2,3	7,5%
LHAR-X VIX Mom/CMA hebdo	6,7%	12,6%	0,53	-0,5	1,9	10%
LHAR-X VIX Mom/RMW hebdo	5,3%	9,9%	0,53	-0,3	1,5	7,5%
LHAR-X VIX Mom/RMW hebdo	4,2%	7,7%	0,55	-0,2	2,2	5%
LHAR-X VIX Mom/T-bills hebdo	3,9%	6,1%	0,63	-0,6	2,9	5%
LHAR-X VIX Mom/T-bills hebdo	5,2%	9,1%	0,57	-0,5	2,0	7,5%
Elastic Net Mom/T-bills hebdo	3,8%	5,9%	0,65	-0,6	2,4	5%
Elastic Net Mom/T-bills hebdo	5,0%	8,8%	0,57	-0,6	2,4	7,5%
LGBM Mom/T-bills hebdo	3,8%	6,0%	0,64	-0,4	1,1	5%
LGBM Mom/T-bills hebdo	5,0%	9,0%	0,55	-0,4	1,2	7,5%

La conclusion est similaire à celle obtenue dans la première partie de l'analyse. Les performances des stratégies sont très élevées : le ratio de Sharpe est environ deux fois supérieur à celui de la stratégie *buy-and-hold* sur le facteur Momentum. En revanche, l'essentiel du gain de performance provient du mécanisme de *volatility targeting* couplé aux prévisions de variance. Les différences de performance entre les différents modèles de prévision de la variance restent relativement limitées en termes de gains de ratio de Sharpe.

Dans cette seconde analyse, les stratégies sont mises en œuvre à partir de début 2010. Le fait que les gains de performance observés soient du même ordre de grandeur que ceux obtenus en commençant en 2001 est un résultat rassurant. Cela suggère que les bénéfices du *volatility targeting* et de l'utilisation des prévisions de variance ne sont pas spécifiques à une période particulière, mais qu'ils restent robustes sur des sous-périodes distinctes et dans des environnements de marché différents.

## Conclusion

Ce projet étudie la prévision de la volatilité du facteur Momentum et son utilisation dans des stratégies d'allocation dynamique du risque. Les résultats mettent en évidence plusieurs enseignements clés, tant sur le plan statistique que sur le plan économique.

Le premier résultat majeur concerne l'efficacité des stratégies de *volatility targeting*. Les gains de performance les plus significatifs ne proviennent pas du choix du modèle de prévision en tant que tel, mais du passage d'une exposition statique à une gestion dynamique du risque. L'ajustement de l'exposition au facteur Momentum en fonction de la volatilité anticipée permet de presque doubler le ratio de Sharpe (d'environ 0,28 à près de 0,60) et de réduire fortement l'asymétrie négative des rendements, en limitant l'exposition aux épisodes de *momentum crashes*. Ce résultat est robuste sur différentes périodes d'échantillonnage et différents actifs de repli.

Le second enseignement concerne la comparaison entre modèles économétriques et modèles de machine learning. Les approches de machine learning, en particulier l'Elastic Net et les méthodes d'ensemble, offrent des améliorations modestes mais systématiques par rapport aux benchmarks économétriques de type LHAR-X. Leur principal avantage réside dans leur capacité à exploiter un grand nombre de variables macro-financières via des mécanismes de régularisation et de réduction de dimension, tout en évitant le sur-apprentissage dans un contexte de changements fréquents de régime.

Dans l'ensemble, ces résultats suggèrent que la valeur ajoutée principale réside dans l'utilisation de prévisions de volatilité pour piloter dynamiquement le risque, tandis que les modèles de machine learning constituent un

complément utile aux approches économétriques classiques pour exploiter une information macroéconomique riche, sans remettre en cause la simplicité et la robustesse des stratégies de gestion du risque mises en œuvre.